

Redes Neurais Profundas e Algoritmos Hierárquicos de Pathfinding para Computação de Elevação e Inclinação na Descoberta de Caminhos em Terrenos Virtuais

Resumo. *Técnicas de busca de caminhos (pathfinding) e de redes neurais profundas vêm recebendo crescente destaque por permitir resolver diferentes problemas do mundo real. Mesmo diante deste cenário, tais técnicas ainda não são investigadas de forma integrada visando resolver problemas onde informações topográficas de terrenos virtuais de grandes dimensões são exploradas. Para atacar esse problema, este trabalho busca implementar e analisar algoritmos hierárquicos de pathfinding. Funções heurísticas utilizadas por esses algoritmos são computadas por redes neurais profundas, as quais são treinadas a partir de caminhos determinados a partir de informações de elevação e inclinação representadas nos mapas virtuais.*

1. Introdução

Pathfinding é o planejamento para resolver problemas de busca em grafos onde o objetivo é encontrar uma rota de menor custo entre dois pontos. A determinação desta rota por algoritmos de pathfinding [Algfoor *et al.*, 2015] pode ser avaliada por diferentes critérios, tais como: tempo, distância, consumo de energia, elevação, inclinação e curvas do terreno, entre outros. Baseado em um grafo ponderado que representa o terreno, um nodo inicial e um nodo final, o algoritmo A* utiliza uma função de custo $f(n) = g(n) + h(n)$ para avaliar os nodos do grafo. Enquanto $g(n)$ indica o custo do caminho até o nodo (n), uma função de heurística $h(n)$ estima o custo de (n) até uma posição de destino, em cada etapa do processo de busca. Funções heurísticas tradicionais, tais como distância Euclidiana e de Manhattan, por exemplo, são comumente exploradas por algoritmos de pathfinding orientando a busca em mapas de escala relativamente pequena. Tais algoritmos, contudo, podem não produzir resultados satisfatórios em mapas com muitos obstáculos ou quando outras características do terreno são analisadas durante a busca.

O objetivo deste trabalho é explorar o uso de redes neurais profundas (Deep Neural Networks – DNN) [Goodfellow *et al.*, 2016] na computação de valores heurísticos de distância a serem usados por algoritmos hierárquicos de pathfinding. Tal como proposto em [Daniel *et al.*, 2010], algoritmos hierárquicos de pathfinding permite dividir os mapas de grandes dimensões em clusters, representando clusters e bordas entre eles em um grafo abstrato. Em um passo preliminar de busca, esses algoritmos computam menores caminhos entre nodos A e B nesse grafo abstrato. Em seguida, caminhos encontrados no primeiro passo de busca são refinados e suavizados em cada um dos clusters envolvidos. Diferente de outros trabalhos que integram técnicas de pathfinding e aprendizado de máquina [Jindal *et al.*, 2017], [Li *et al.*, 2016], [Takahashi

et al., 2019], o problema a ser tratado nesta pesquisa é o desenvolvimento e teste de algoritmos hierárquicos de pathfinding para problemas que considerem informações de elevação e inclinação do terreno virtual nas computações realizadas.

2. Revisão da Literatura

DNN [Goodfellow *et al.*, 2016] são uma classe de algoritmos de aprendizado de máquina que usam várias camadas de uma arquitetura de rede neural artificial. Tais arquiteturas permitem extrair progressivamente recursos de nível superior da entrada bruta da rede neural para níveis inferiores até obtenção de uma saída desejada. Esses algoritmos possuem i) uma camada de entrada onde os padrões são apresentados à rede, ii) camadas intermediárias ou ocultas onde a maior parte do processamento é realizado, por meio de conexões ponderadas, as quais podem ser considerados extratores de características, e iii) uma camada de saída onde o resultado final é apresentado.

Abordagens para o emprego de DNN na computação de algoritmos de pathfinding são recentemente descritas na literatura. [Jindal *et al.*, 2017] usam uma DNN denominada ST-NN (Rede Neural Espacial-Temporal) para estimar tempo de viagem do serviços de transporte em táxi. [Takahashi *et al.*, 2019] propõem a utilização da rede neural U-Net para extrair e utilizar e imagens de mapas coletadas para usar no aprendizado de heurísticas utilizadas para criar rotas para robôs. [Li *et al.*, 2016] propõem um algoritmo ANN* de busca heurística em grids baseado em DNN onde uma heurística é produzida a partir de uma rede neural de regressão. [Doebber 2020] analisa problemas de busca de pathfinding onde DNN são usadas no aprendizado dessas funções heurísticas para melhor orientar a execução da busca de caminhos. O trabalho descreve como preparar as informações de caminho dos mapas virtuais para treinar uma arquitetura de DNN, de forma que a função heurística usada pelo algoritmo de pathfinding aprenda as características do mapa. Apesar dessas contribuições, esses trabalhos não exploram uma abordagem hierárquica de pathfinding baseada no uso de DNN na computação de funções heurísticas, o que pode permitir tratar a otimização do processo de busca em mapas de grandes dimensões.




Figura 1 – (A) Caminhos encontrados pelo algoritmo A* (círculos) e pelo A* tratando inclinações (quadrados), exibidos em um mapa de normais, cujo gradiente indica a variação nas inclinações [Chagas 2019]; (B) Abordagem hierárquica de pathfinding a ser explorada neste trabalho (ilustração de um mapa dividido em clusters e de um caminho entre A e B computado hierarquicamente a partir de informações de elevação e inclinação representadas no mapa virtual).

[Chagas 2019] trata de problemas de pathfinding onde informações de altura e inclinação no terreno são computadas. Esse trabalho propõe um algoritmo de pathfinding que trata informações de altitude do terreno, bem como a suavização dos caminhos encontrados (Fig. 1 A). Para isso, uma técnica denominada “campo de visão”

[Daniel *et al.*, 2010] [Jansen e Buro 2007] é utilizada no planejamento de rotas. Em especial, essa técnica é ajustada para tratar informações que remetem a restrições de elevação e inclinação do terreno, sem utilizar apenas o bloqueio ou não de nodos. O trabalho também busca o caminho de menor custo permitindo evitar inclinações que introduzem riscos a movimentação de agentes inseridos em sistemas de simulação. Em muitos sentidos, os caminhos encontrados são bastante realista, pois pequenos desvios nas rotas encontradas são suavizados, incluindo o retorno de caminhos que podem possuir um custo reduzido, tal como descrito em [Jansen e Buro 2007]. Neste contexto, [Ganganath *et al.*, 2015] e [Sturtevant *et al.*, 2019] também exploram caminhos que permitem o movimento em regiões de terreno que envolvem diferentes características de relevo, tais como terrenos montanhosos com grandes variações de altitude ou contendo inclinações que não permitem o movimento seguro de agentes. Embora tais trabalho apresentem abordagens para a computação de caminhos que consideram informações de relevo dos terrenos usados, ainda existe a necessidade de investigar se os algoritmos propostos podem ser otimizados pelo emprego de abordagens hierárquicas de pathfinding e DNN, tal como proposto neste trabalho.

3. Metodologia

Este trabalho deve explorar uma abordagem hierárquica de pathfinding, onde caminhos são sucessivamente computados e refinados em mapas que são representados em níveis hierárquicos diferentes. Inclinações do terreno representadas nos mapas devem ser usadas pelos algoritmos, em vez de simplesmente considerar que certos nodos são bloqueados para a movimentação de agentes. O trabalho deve propor uma arquitetura de DNN e detalhar como preparar as informações de caminho dos mapas virtuais sendo usados para treiná-la, de forma que a função heurística aprenda as características do mapa. O intuito de usar o DNN é orientar os algoritmos hierárquicos de pathfinding visando reduzir o custo de pesquisa ao lidar com mapas de grandes escalas (Fig. 1 B).

Para gerar os datasets de treinamento das DNN, distâncias entre pontos selecionados aleatoriamente em diferentes regiões do terreno devem ser computadas com um algoritmo de pathfinding que considere elevação e inclinação nas suas avaliações de custo. Para treinar as DNN com caminhos realistas, esses datasets devem também ser construídos a partir do uso de técnicas de suavização de caminhos. Esse conjunto de dados deve ser utilizado para fins de análise de resultados de pathfinding hierárquicos baseados no emprego de DNN como funções heurísticas. Resultados experimentais devem ser produzidos em mapas com diferentes tamanhos e percentuais de elevação e inclinação, considerando mapas com (101x101) nodos, (202x202) nodos, e outros maiores conforme forem as necessidades de análise. Em resumo, os resultados obtidos e analisados devem envolver o uso de pathfinding hierárquico em contraste com o uso do técnicas tradicionais de pathfinding, tal como algoritmo A*, ambos considerando informações de elevação e inclinação dos mapas testados.

Por fim, o trabalho devem ser desenvolvido na linguagem Python, visando a integração e comparação dos resultados obtidos com os resultados de outros trabalhos sendo desenvolvidos no grupo de pesquisa onde este trabalho está inserido. A implementação das DNN deve usar a biblioteca Tensorflow, que é uma biblioteca de software de código aberto para computação numérica que permite utilizar estruturas de

grafos na representação de dados. Mais importante, essa biblioteca vêm se tornando padrão para o desenvolvimento de aplicações envolvendo aprendizado profundo.

4. Considerações Finais

O trabalho pretende contribuir com o estudo de algoritmos hierárquicos de pathfinding baseados em DNN, os quais devem ser ajustados para permitir encontrar caminhos que considerem características topográficas dos terrenos virtuais. Testes dos algoritmos desenvolvidos devem ser realizados em terrenos virtuais com diferentes dimensões e características de relevo, permitindo medir o impacto dessas características na performance dos algoritmos implementados. Os resultados obtidos devem ser avaliados estatisticamente, permitindo desenvolver um contraste entre os algoritmos e experimentos desenvolvidos.

Referências

- Algfoor A., Sunar M. S. e Kolivand H. (2015) "A comprehensive study on pathfinding techniques for robotics and video games," *Int. Journal of Computer Games Technology*.
- Daniel, K., Nash, A., Koenig, S., and Felner, A. (2010) "Theta*: Any-angle path planning on grids". *Journal of Artificial Intelligence Research* 39:533–579.
- Goodfellow I., Bengio Y. e Courville A. (2016) "Deep learning". MIT press.
- Jindal, I. Qin, T e Xueue, Q. (2017) "A unified neural network approach for estimating travel time and distance for a taxi trip". *arXiv preprint arXiv:1710.04350*.
- Takahashi T., Sun H., Tian T. e Wang Y. (2019) "Learning Heuristic Functions for Mobile Robot Path Planning Using Deep Neural Networks". *Proceedings of the International Conference on Automated Planning and Scheduling*, 2019. p.764-772.
- Li, G., Wang, H., Wang, N. e Yeung Y. (2016) "ANN: a heuristic search algorithm based on artificial neural networks". *Proceedings of the 2016 International Conference on Intelligent Information Processing*. ACM. p.51.
- Doebber, D. M. (2019) "Uso de redes neurais profundas para o aprendizado de funções heurísticas para algoritmos de busca de caminhos." *Trabalho de Conclusão do Curso de Ciência da Computação*. Santa Maria: Universidade Federal de Santa Maria.
- Chagas, C. (2019) "Algoritmos de busca de caminhos voltados para informações de altura e inclinação representadas em mapas de navegação", *Trabalho de Conclusão do Curso de Ciência da Computação*. Universidade Federal de Santa Maria.
- Ganganath, N., Cheng, C.-T., Chi, K. T. (2015) "A constraint-aware heuristic path planner for finding energy-efficient paths on uneven terrains", *IEEE transactions on industrial informatics*, v. 11, n. 3, p. 601-611.
- Jansen, M.R., Buro, M., (2007) "HPA* enhancements". *Proceedings of the Third Artificial Intelligence and Interactive Digital Entertainment Conference*, Stanford, California, USA, pp. 84–87.
- Sturtevant, N. R., Sigurdson, D., Taylor, B., & Gibson, T. (2019) "Pathfinding and Abstraction with Dynamic Terrain Costs". *Proceedings of the AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment*, 15(1), 80-86.